

B3-1

系统输入:

糖质信息获取和数据解码。开发精确高效的糖质序列或结构测量技术，实现对糖质序列信息的快速读取，形成重要生理或疾病过程相关的高精度、高深度、标准化糖质数据资源，开发针对糖质谱组学数据或测序数据的分析流程及定量软件；利用先进算法和机器学习技术，结合时空多组学等手段，挖掘糖质承载的生命信息和参与调控的信号网络，探索糖质信息编码规律及调控机制。

系统输出:

科学发现提案:

Glyco-Decipher: 基于深度图学习的糖质序列高通量解码与功能图谱构建

1. 研究背景与意义

1.1 生命科学的“暗物质”

核酸和蛋白质的测序技术已臻成熟，推动了基因组学和蛋白质组学的爆发。然而，作为生命第三大类生物大分子，**聚糖（Glycans）** 具有非模板驱动、高度分支和异构化的特性。现有的分析手段（如 HPLC、质谱）面临“读不懂、测不准、对不上”的困境。

1.2 糖质编码（Glyco-Code）的破译需求

细胞表面的糖链如同“条形码”，调控着病毒入侵（如流感、新冠）、肿瘤免疫逃逸和神经发育。目前的瓶颈在于缺乏一套像 BLAST 那样高效的序列比对工具，以及像 GenBank 那样标准化的结构数据库。本研究旨在建立糖质测序的“摩尔定律”，实现从定性到定量的飞跃。

2. 核心科学问题与假设

2.1 质谱-拓扑映射假设 (Spectral-Topological Mapping)

H_0 : 对于任意一个复杂的糖链拓扑结构 G ，其多级串联质谱 (MS^n) 产生的碎片离子集合 S ，存在一个双射函数 f ，使得：

$$G = f^{-1}(S \mid \theta)$$

其中 θ 是物理环境参数（碰撞能量、离子化模式）。这意味着只要算法足够强大，我们可以仅通过碎片指纹重构出唯一的糖链分支结构，而无需依赖标准品。

2.2 糖功能的信息熵阈值

我们假设糖链的生物学功能密度与其结构的信息熵（Shannon Entropy）正相关。当糖链的分支复杂度 C_{branch} 超过特定阈值 δ 时，其携带的生物信息量呈指数级上升，成为细胞间通讯的主要载体。

$$\text{Info}(\text{Glycan}) \propto \exp(\alpha \cdot C_{\text{branch}})$$

3. 研究计划与技术路线

3.1 第一阶段：超高分辨糖质谱采集技术 (第 1-12 个月)

任务：开发“软硬结合”的糖链指纹采集系统。

- 硬件创新**：结合离子淌度质谱 (IM-MS) 与电子活化解离 (ExD) 技术，在分离同分异构体 (Isomers) 的同时，保留不稳定的唾液酸修饰。
- 标准化建库**：构建包含 10,000 种合成糖标准品的 **Glyco-Standard-Atlas**，记录其保留时间、碰撞截面 (CCS) 和 MS² 碎片图谱，作为“罗塞塔石碑”。

3.2 第二阶段：AI 驱动的 De Novo 测序算法 (第 13-24 个月)

任务：开发 Glyco-BERT 数据解码软件。

- 图神经网络 (GNN) 表征**：将糖链视为图结构（单糖为节点，糖苷键为边），利用 GNN 学习糖链断裂的物理规律。
- 端到端测序**：输入原始质谱数据，直接输出预测的 IUPAC 糖链序列，解决“盲测”难题。

3.3 第三阶段：时空糖组学与功能调控网络 (第 25-36 个月)

任务：挖掘糖质数据的生命意义。

- 空间糖组学**：利用 MALDI-Imaging 技术，绘制肿瘤组织切片上的“糖链地图”，寻找肿瘤微环境中的特异性糖抗原。
- 多组学关联**：整合“转录组-糖基转移酶-糖组”数据，通过因果推断 (Causal Inference) 揭示基因变异如何导致糖链修饰异常，进而引发疾病。

4. 关键技术演示：糖链组成推断算法

在糖质谱分析中，第一步通常是根据母离子质量 (Precursor Mass) 推断可能的单糖组成（如：多少个己糖、多少个唾液酸）。这是一个典型的**数论组合问题**。

以下 Python 代码展示了一个高效的递归算法，用于计算给定质量下的所有可能糖组成：

```
import pandas as pd
from typing import List, Dict, Optional

# ( )
MONOSACCHARIDES = {
    'Hex': 162.0528, # ( , )
    'HexNAc': 203.0794, # N-
    'Fuc': 146.0579, #
    'Neu5Ac': 291.0954 #
}

class GlycoCompositionSolver:
    def __init__(self, tolerance_ppm: float = 10.0):
        self.ppm = tolerance_ppm
        self.results = []

    def solve(self, target_mass: float, max_counts: Dict[str, int]):
        """
        target_mass
        """
        self.results = []
        monos = list(MONOSACCHARIDES.items())
        #
        self._recursive_search(target_mass, monos, {}, max_counts)
        return pd.DataFrame(self.results)

    def _recursive_search(self, remaining_mass: float,
                          monos_left: List, current_comp: Dict):

        # ( )
        error = abs(remaining_mass)
        # ( H/OH )
        #

        if not monos_left:
            # ppm
            ppm_error = (remaining_mass / (target_mass -
            remaining_mass)) * 1e6
```

```

        if abs(ppm_error) <= self.ppm:
            self.results.append(current_comp.copy())
        return

name, mass = monos_left[0]
max_n = max_counts.get(name, 10) #

# (0 max_n)
for count in range(max_n + 1):
    mass_deduction = mass * count
    if mass_deduction > remaining_mass + 1.0: #
        break

#
current_comp[name] = count

#
self._recursive_search(
    remaining_mass - mass_deduction,
    monos_left[1:],
    current_comp
)

# ---
# 2222.78 Da ( N- )
# (18.0106)
target_mass = 2222.78
solver = GlycoCompositionSolver(tolerance_ppm=20.0)

# ( 12 Hex)
constraints = {'Hex': 12, 'HexNAc': 10, 'Fuc': 5, 'Neu5Ac': 4}

df_compositions = solver.solve(target_mass, constraints)

print(f" {len(df_compositions)} :")
if not df_compositions.empty:
    print(df_compositions.head())
# :

```

#	Hex	HexNAc	Fuc	Neu5Ac	
# 0	5	4	2	2	(N-)

5. 预期成果与影响

5.1 科学交付成果

- DeepGlyco 软件套件**: 集成了“组成鉴定-拓扑测序-定量分析”的一站式开源平台，支持 Thermo/Bruker/Waters 等主流质谱数据格式。
- PDB-Glyco 数据库**: 全球最大的结构确证糖质数据库，包含超过 50,000 个高置信度糖链结构及其对应的时空表达谱。
- 糖密码词典**: 解析出 50 种与肿瘤转移高度相关的“糖基化模体 (Motifs)”。

5.2 临床与产业价值

- 新型生物标志物**: 发现比蛋白质更早期的癌症筛查指标（如肝癌中的异常岩藻糖化）。
- 生物制药质控**: 为单克隆抗体药物 (mAb) 提供原子级精度的糖型分析方案，确保药物的均一性和安全性，加速 FDA 审批流程。

6. 图表与附录

6.1 核心公式补充：糖链图编辑距离

为了量化两个糖链结构 和 之间的相似度（用于数据库搜索），我们定义**树编辑距离 (Tree Edit Distance, TED)**:

$$TED(G_1, G_2) = \min \sum \text{cost}(\text{op}_i)$$

其中操作 包括:

- 节点替换** (将葡萄糖变为半乳糖)
- 边断裂/连接** (改变糖苷键连接位点, 如 α -1,3 $\rightarrow$ α -1,6)
- 子树修剪** (丢失某个分支)

该指标将作为我们机器学习模型中的核心损失函数 (Loss Function)。