

B4-1

系统输入:

糖质功能语言的AI解析与应用。针对特定生理或病理过程，发展糖质功能解析的零样本预测模型；利用视频分析和图神经网络技术，整合分子组学与表型组数据，在群体层面上定量解析糖质合成酶、修饰酶、糖苷酶和糖蛋白的功能效应；利用机器推理技术，实现糖质分子网络的可解释性推断，为基于糖质的疾病干预提供新思路 and 策略。

系统输出:

科学发现提案:

Glyco-Reason: 糖质功能语言的零样本解析与因果推断引擎

1. 研究背景与意义

1.1 糖质——细胞表面的“第三种语言”

如果说 DNA 是生命的蓝图，蛋白质是执行者，那么糖质（Glycans）就是细胞社交的“语言”和“身份证”。然而，糖质功能的编码规则极其晦涩：它不遵循中心法则的模板复制，而是由数百种糖苷酶和糖基转移酶在内质网/高尔基体中动态竞争合成的。

1.2 从“结构观测”到“语义理解”的跨越

目前的瓶颈在于：我们虽然能测出糖链结构，却无法预测其功能（如：为什么加上一个岩藻糖就能让肿瘤免疫逃逸？）。本研究旨在利用 AI 将糖质研究从“结构组学”推向“功能语义学”，特别是利用零样本学习（Zero-Shot Learning）技术，预测从未见过的糖链变体在特定病理过程中的功能，破解糖质密码。

2. 核心科学问题与假设

2.1 糖-表型因果映射假设 (Glyco-Phenotype Causality)

H_0 : 细胞的宏观表型 P （如迁移速度、粘附力）是糖合成酶网络 E 的函数，该函数通过糖链结构分布 G 进行中介。

$$P(t) = \Phi(G(E(t)))$$

其中 Φ 是我们需要学习的“语义映射函数”。我们假设该函数具有**子图可加性**：复杂糖链的功能可以分解为若干个“功能性基序 (Functional Motifs)”的非线性组合。

2.2 零样本泛化猜想

若 AI 模型学会了糖残基与蛋白质受体结合的**物理化学语法规则**（如氢键模式、静电势互补），则对于训练集中未出现的全新糖链 G_{new} ，模型仍能准确预测其结合亲和力与生物学效应。

$$\text{Error}(\text{Prediction}(G_{new})) < \epsilon$$

3. 研究计划与技术路线

3.1 第一阶段：多模态数据工厂——视频与组学整合 (第 1-12 个月)

任务：建立“酶-糖-表型”关联的大数据基座。

- 群体级酶学扰动：**利用 CRISPR-Cas9 在细胞系中构建全基因组糖基化酶（约 200 个基因）的单敲除和组合敲除文库。
- 视频表型组分析 (Video Phenomics)：**
 - 利用高内涵显微镜拍摄细胞在 24 小时内的动态行为。
 - 技术核心：**开发基于 **Vision Transformer (ViT)** 的视频分析算法，自动提取细胞的动态特征（如：伪足伸缩频率、细胞间碰撞后的反弹/粘附行为），量化糖被 (Glycocalyx) 改变对细胞社交的影响。

3.2 第二阶段：糖质功能的零样本预测模型 (第 13-24 个月)

任务：构建 Glyco-GNN 预测引擎。

- 图神经网络编码：**将糖链建模为异构图（节点=单糖，边=糖苷键类型），利用 GNN 提取结构特征嵌入 (Embedding)。
- 神经符号推理 (Neuro-Symbolic Reasoning)：**
 - 不只是黑盒预测，而是引入逻辑规则。例如：
 - 规则 A：**若末端存在 Sialic Acid (α 2-3) Gal，则大概率结合 Siglec 受体 $\rightarrow$ 抑制免疫。
 - 模型将学习这些规则的权重，实现对未见糖链的**逻辑推演**。

3.3 第三阶段：可解释性网络推断与干预策略 (第 25-36 个月)

任务：为疾病干预提供靶点。

- 反事实推理 (Counterfactual Reasoning)：**
 - 询问 AI：“如果将患者肿瘤细胞表面的核心岩藻糖去除 50%，其转移概率会下降多少？”

- 通过构建因果结构模型 (Structural Causal Model, SCM) 来回答此类 “What-if” 问题。
2. **干预策略生成**：寻找能够阻断特定病理糖链合成的 “最小酶干预组合”，指导小分子抑制剂的开发。

4. 关键技术演示：神经符号推理伪代码

以下 Python 代码片段展示了如何结合深度学习的特征提取与逻辑规则的显式推理，来解析糖链是否具有免疫抑制功能。

```
import torch
import torch.nn as nn
from dgl.nn import GraphConv

class NeuroSymbolicGlycoNet(nn.Module):
    def __init__(self, in_dim, hidden_dim, num_classes):
        super().__init__()
        # 1. (Neural Module): GNN
        self.conv1 = GraphConv(in_dim, hidden_dim)
        self.conv2 = GraphConv(hidden_dim, hidden_dim)

        # 2. (Symbolic Module):
        # K ( : has_sialic_acid,
        # is_branched...)
        self.logic_weights = nn.Parameter(torch.randn(5))

    def forward(self, g, features, existence_vector):
        """
        g:
        features:
        existence_vector: (
        )
        : [has_Sia, has_Fuc,
        has_Bisecting...]
        """
        # --- ( ) ---
        h = self.conv1(g, features)
        h = torch.relu(h)
        h = self.conv2(g, h)
        g.ndata['h'] = h
        # (Readout)
```

```

neural_score = dgl.mean_nodes(g, 'h')

# --- ( ) ---
# : Score = w1 * Has_Sia + w2 * Has_Fuc ...
# w
symbolic_score = torch.matmul(existence_vector,
self.logic_weights)

# --- ---
#
final_output = torch.sigmoid(neural_score + symbolic_score)

return final_output, self.logic_weights

#
def explain_decision(logic_weights):
    features = ["", "", "GlcNAc", ""]
    print("--- AI ---")
    weights = logic_weights.detach().numpy()
    for feature, w in zip(features, weights):
        effect = "" if w > 0 else ""
        print(f" : [{feature}] {effect} ( : {w:.2f})")

# :
# --- AI ---
# : [ ] ( : 2.14)
# : [ GlcNAc ] ( : -1.05)

```

5. 预期成果与影响

5.1 科学交付成果

1. **Glyco-Zero 模型**：首个糖质功能零样本预测平台，在未见过的糖链结构上预测准确率 > 80%。
2. **酶效量化图谱**：首次在群体层面量化 200 种糖相关酶对细胞宏观行为（视频特征）的贡献度矩阵。
3. **可解释因果网络**：通过机器推理构建的“酶 糖 疾病”因果图，明确区分“伴随性改变”与“致病性改变”。

5.2 临床价值

- 虚拟药物筛选**：在计算机中模拟敲除特定糖苷酶后，肿瘤细胞表面糖被的改变及其对 CAR-T 疗法疗效的增益，从而筛选最佳联合治疗靶点。
- 精准诊断**：基于糖质功能评分（而非仅仅是含量）的新型液体活检指标。

6. 图表与附录

6.1 核心公式补充：子图匹配与注意力机制

为了实现零样本预测，我们采用基于注意力的子图匹配算法。糖链 G 的功能得分 $F(G)$ 定义为：

$$F(G) = \sum_{i=1}^N \text{Attention}(S_i, \text{Target}) \cdot \text{Weight}(S_i)$$

其中 S_i 是糖链 G 中的第 i 个子结构（Sub-graph），Target 是目标蛋白（如病毒受体）的结构嵌入。Attention 项衡量了该子结构与受体的**物理兼容性**。

